

Multiple Choice

Econometrics - Chapter 26

Mateus Lee Yu Wesley Cabral Alves

2026-06-05

Introdução

- Definição: O par (Y, X) é uma resposta multinomial quando $X \in \mathbb{R}^k$ e Y é multinomial, ou seja, Y pertence a um conjunto finito de alternativas ($Y \in \{1, \dots, J\}$).
- Probabilidade de resposta: É a distribuição condicional de Y dado X ,

$$P_j(x) = \mathbb{P}[Y = j | X = x].$$

- Exemplo: Y o estado civil (“casado”, “divorciado”, “separado”, “nunca casado”) e X a idade.
- A resposta multinomial é motivado e derivado pelo modelo de utilidade latente.

- A utilidade da alternativa j é dado por

$$U_j^* = X_j' \beta_j + \epsilon_j,$$

onde β_j é o coeficiente e ϵ_j o erro da alternativa j .

- No modelo de utilidade latente, o indivíduo assume a alternativa com maior utilidade, ou seja, $Y = j$ se $U_j^* \geq U_l^*$ para todo l .
- Se somarmos $X_j' \gamma$ para cada utilidade a escolha da alternativa não muda, logo os coeficientes β_j não são separadamente identificados.
- Portanto, escolhemos uma alternativa base j e fixamos $\beta_j = 0$ para que a diferença dos coeficientes $\beta_j - \beta_l$ seja identificado.
- Os dois modelos de respostas multinomiais clássicos são os modelos Logit e Probit.

Modelo Logit

- Definição 26.1: A distribuição de Valor Extremo Tipo I é dado por

$$F(\epsilon) = \exp(-\exp(-\epsilon)).$$

- Definição 26.2: A distribuição conjunta Generalized Extreme Values (GEV) é dado por

$$F(\epsilon_1, \dots, \epsilon_J) = \exp \left(- \left[\sum_{j=1}^J \exp \left(\frac{\epsilon_j}{\tau} \right) \right] \right),$$

onde $0 < \tau \leq 1$.

- Observação: Quando $\tau = 1$, a distribuição GEV coincide com a distribuição de $(\epsilon_1, \dots, \epsilon_J)$ i.i.d. com distribuição de Valor Extremo Tipo I.

- Teorema 26.1: Assuma que a utilidade da alternativa j é dado por $U_j^* = X' \beta_j + \epsilon_j$, e o vetor de erros $(\epsilon_1, \dots, \epsilon_J)$ com distribuição GEV. Então, as probabilidades de resposta são dadas por

$$P_j(x) = \frac{\exp(x' \beta_j / \tau)}{\sum_{l=1}^J \exp(x' \beta_l / \tau)}.$$

- Por conveniência algébrica utilizamos $\tau = 1$.
- Definição: O modelo simples Logit é dado por

$$P_j(x) = \frac{\exp(x' \beta_j)}{\sum_{l=1}^J \exp(x' \beta_l)}.$$

- Para a observação $\{Y_i, X_i\}$ e coeficientes $\beta = (\beta_1, \dots, \beta_J)$, temos que a função de distribuição

$$\pi(Y_i|X_i, \beta) = \prod_{j=1}^J P_j(X_i|\beta)^{\mathbf{I}\{Y_i=j\}}.$$

- Então a função de log-verossimilhança é dada por

$$l_n(\beta) = \sum_{i=1}^n \sum_{j=1}^J \mathbf{I}\{Y_i = j\} \log P_j(X_i|\beta).$$

- O estimador de máxima verossimilhança, $\hat{\beta} = \underset{\beta}{\operatorname{argmax}} l_n(\beta)$, não tem solução fechada, portanto deve ser encontrada numericamente.
- Observe que a função de verossimilhança é côncava, então a maximização é direta.

Interpretação

- Os coeficientes são difíceis de interpretar, portanto na prática utilizamos os efeitos marginais.
- O efeito marginal da alternativa j é dado por

$$\delta_j(x) = \frac{\partial}{\partial x} P_j(x) = P_j(x) \left(\beta_j - \sum_{l=1}^J \beta_l P_l(x) \right),$$

e estimador por

$$\hat{\delta}_j(x) = \hat{P}_j(x) \left(\hat{\beta}_j - \sum_{l=1}^J \hat{\beta}_l \hat{P}_l(x) \right).$$

- E a média do efeito marginal, $AME_j = \mathbb{E}[\delta_j(X)]$, é estimador por

$$\widehat{AME}_j = \frac{1}{n} \sum_{i=1}^n \hat{\delta}_j(X_i).$$

Modelo Logit Condicional

- Exemplo: Suponha que estamos interessados no modo de transporte dos estudantes (“andando”, “bicicleta”, “ônibus”, “trem”, “carro”). Diversos fatores influenciam a escolha do modo de transporte, mas principalmente o custo, que depende do indivíduo e das alternativas.
- O modelo Logit condicional é dado por

$$U_j^* = W' \beta_j + X_j' \gamma + \epsilon_j.$$

- Sob a suposição de que $(\epsilon_1, \dots, \epsilon_J)$ são i.i.d. com distribuição de Valor Extremo Tipo I. A partir do Teorema 26.1, as probabilidades de resposta são dadas por

$$P_j(w, x) = \frac{\exp(w' \beta_j + x_j' \gamma)}{\sum_{l=1}^J \exp(w' \beta_l + x_l' \gamma)}.$$

- Para as observações $\{Y_i, W_i, X_i\}$, onde $X_i = \{X_{1i}, \dots, X_{Ji}\}$, a função de log-verossimilhança é dada por

$$l_n(\beta, \gamma) = \sum_{i=1}^n \sum_{j=1}^J \mathbf{I}\{Y_i = j\} \log P_j(W_i, X_i | \beta, \gamma).$$

- Novamente o estimador de máxima verossimilhança $\widehat{\beta, \gamma} = \underset{\beta, \gamma}{\operatorname{argmax}} l_n(\beta, \gamma)$ não tem solução fechada e deve ser encontrada numericamente.
- Os efeitos marginais são dados por

$$\delta_{jj}(w, x) = \frac{\partial}{\partial x_j} P_j(w, x) = \gamma P_j(w, x)(1 - P_j(w, x))$$

e

$$\delta_{jl}(w, x) = \frac{\partial}{\partial x_l} P_j(w, x) = -\gamma P_j(w, x) P_l(w, x) \quad \text{para } j \neq l,$$

e estimados substituindo por $\hat{\gamma}$, $\hat{P}_j(w, x)$ e $\hat{P}_l(w, x)$.

- A média do efeito marginal, $\text{AME}_j = \mathbb{E}[\delta_j(X)]$, é estimador pela média de $\delta_{jl}(w_i, x_i)$.

- Independência das Alternativas Irrelevantes

Modelos Probit

Probit Multinomial

- Definição
- Erros
- GHK

- Definição
- Erros
- Exemplos

Modelos de Contagem

Regressões Poisson e Binomial Negativa

- Definição
- Particularidades

Modelo BLP (Nerry, Levinsohn e Parkes)

- Definição (GMM)
- Erros
- Exemplos

Aplicação

