

Multiple Choice

Econometrics - Chapter 26

Mateus Lee Yu Wesley Cabral Alves

2026-06-09

Introdução

- Definição: O par (Y, X) é uma resposta multinomial quando $X \in \mathbb{R}^k$ e Y é multinomial, ou seja, Y pertence a um conjunto finito de alternativas ($Y \in \{1, \dots, J\}$).
- Probabilidade de resposta: É a distribuição condicional de Y dado X ,

$$P_j(x) = \mathbb{P}[Y = j | X = x].$$

- Exemplo: Y o estado civil (“casado”, “divorciado”, “separado”, “nunca casado”) e X a idade.
- A resposta multinomial é motivado e derivado pelo modelo de utilidade latente.

- A utilidade da alternativa j é dado por

$$U_j^* = X_j' \beta_j + \epsilon_j,$$

onde β_j é o coeficiente e ϵ_j o erro da alternativa j .

- No modelo de utilidade latente, o indivíduo assume a alternativa com maior utilidade, ou seja, $Y = j$ se $U_j^* \geq U_l^*$ para todo l .
- Se somarmos $X_j' \gamma$ para cada utilidade a escolha da alternativa não muda, logo os coeficientes β_j não são separadamente identificados.
- Portanto, escolhemos uma alternativa base j e fixamos $\beta_j = 0$ para que a diferença dos coeficientes $\beta_j - \beta_l$ seja identificado.
- Os dois modelos de respostas multinomiais clássicos são os modelos Logit e Probit.

Modelo Logit

- Definição 26.1: A distribuição de Valor Extremo Tipo I é dado por

$$F(\epsilon) = \exp(-\exp(-\epsilon)).$$

- Definição 26.2: A distribuição conjunta Generalized Extreme Values (GEV) é dado por

$$F(\epsilon_1, \dots, \epsilon_J) = \exp \left(- \left[\sum_{j=1}^J \exp \left(\frac{\epsilon_j}{\tau} \right) \right] \right),$$

onde $0 < \tau \leq 1$.

- Observação: Quando $\tau = 1$, a distribuição GEV coincide com a distribuição de $(\epsilon_1, \dots, \epsilon_J)$ i.i.d. com distribuição de Valor Extremo Tipo I.

- Teorema 26.1: Assuma que a utilidade da alternativa j é dado por $U_j^* = X' \beta_j + \epsilon_j$, e o vetor de erros $(\epsilon_1, \dots, \epsilon_J)$ com distribuição GEV. Então, as probabilidades de resposta são dadas por

$$P_j(x) = \frac{\exp(x' \beta_j / \tau)}{\sum_{l=1}^J \exp(x' \beta_l / \tau)}.$$

- Por conveniência algébrica utilizamos $\tau = 1$.
- Definição: O modelo simples Logit é dado por

$$P_j(x) = \frac{\exp(x' \beta_j)}{\sum_{l=1}^J \exp(x' \beta_l)}.$$

- Para a observação $\{Y_i, X_i\}$ e coeficientes $\beta = (\beta_1, \dots, \beta_J)$, temos que a função de distribuição

$$\pi(Y_i|X_i, \beta) = \prod_{j=1}^J P_j(X_i|\beta)^{\mathbf{I}\{Y_i=j\}}.$$

- Então a função de log-verossimilhança é dada por

$$l_n(\beta) = \sum_{i=1}^n \sum_{j=1}^J \mathbf{I}\{Y_i = j\} \log P_j(X_i|\beta).$$

- O estimador de máxima verossimilhança, $\hat{\beta} = \underset{\beta}{\operatorname{argmax}} l_n(\beta)$, não tem solução fechada, portanto deve ser encontrada numericamente.
- Observe que a função de verossimilhança é côncava, então a maximização é direta.

Interpretação

- Os coeficientes são difíceis de interpretar, portanto na prática utilizamos os efeitos marginais.
- O efeito marginal da alternativa j é dado por

$$\delta_j(x) = \frac{\partial}{\partial x} P_j(x) = P_j(x) \left(\beta_j - \sum_{l=1}^J \beta_l P_l(x) \right),$$

e estimador por

$$\hat{\delta}_j(x) = \hat{P}_j(x) \left(\hat{\beta}_j - \sum_{l=1}^J \hat{\beta}_l \hat{P}_l(x) \right).$$

- E a média do efeito marginal, $AME_j = \mathbb{E}[\delta_j(X)]$, é estimador por

$$\widehat{AME}_j = \frac{1}{n} \sum_{i=1}^n \hat{\delta}_j(X_i).$$

Modelo Logit Condicional

- Exemplo: Suponha que estamos interessados no modo de transporte dos estudantes (“andando”, “bicicleta”, “ônibus”, “trem”, “carro”). Diversos fatores influenciam a escolha do modo de transporte, mas principalmente o custo, que depende do indivíduo e das alternativas.
- O modelo Logit condicional é dado por

$$U_j^* = W' \beta_j + X_j' \gamma + \epsilon_j.$$

- Sob a suposição de que $(\epsilon_1, \dots, \epsilon_J)$ são i.i.d. com distribuição de Valor Extremo Tipo I. A partir do Teorema 26.1, as probabilidades de resposta são dadas por

$$P_j(w, x) = \frac{\exp(w' \beta_j + x_j' \gamma)}{\sum_{l=1}^J \exp(w' \beta_l + x_l' \gamma)}.$$

- Para as observações $\{Y_i, W_i, X_i\}$, onde $X_i = \{X_{1i}, \dots, X_{Ji}\}$, a função de log-verossimilhança é dada por

$$l_n(\beta, \gamma) = \sum_{i=1}^n \sum_{j=1}^J \mathbf{I}\{Y_i = j\} \log P_j(W_i, X_i | \beta, \gamma).$$

- Novamente o estimador de máxima verossimilhança $\widehat{\beta, \gamma} = \underset{\beta, \gamma}{\operatorname{argmax}} l_n(\beta, \gamma)$ não tem solução fechada e deve ser encontrada numericamente.
- Os efeitos marginais são dados por

$$\delta_{jj}(w, x) = \frac{\partial}{\partial x_j} P_j(w, x) = \gamma P_j(w, x)(1 - P_j(w, x))$$

e

$$\delta_{jl}(w, x) = \frac{\partial}{\partial x_l} P_j(w, x) = -\gamma P_j(w, x) P_l(w, x) \quad \text{para } j \neq l,$$

e estimados substituindo por $\hat{\gamma}$, $\hat{P}_j(w, x)$ e $\hat{P}_l(w, x)$.

- A média do efeito marginal, $\text{AME}_j = \mathbb{E}[\delta_j(X)]$, é estimador pela média de $\delta_{jl}(w_i, x_i)$.

- Independência das Alternativas Irrelevantes (Independence of Irrelevant Alternative ou IIA) é uma propriedade do modelo Logit,

$$\begin{aligned}\frac{P_j(W, X|\beta, \gamma)}{P_l(W, X|\beta, \gamma)} &= \frac{\exp(W' \beta_j + X'_j \gamma) / \sum_{k=1}^J \exp(w' \beta_k + x'_k \gamma)}{\exp(W' \beta_l + X'_l \gamma) / \sum_{k=1}^J \exp(w' \beta_k + x'_k \gamma)} \\ &= \frac{\exp(W' \beta_j + X'_j \gamma)}{\exp(W' \beta_l + X'_l \gamma)}.\end{aligned}$$

- Problema Clássico: Suponha que as alternativas de transporte carro ($j = 1$) e ônibus vermelho ($j = 2$) tem probabilidades de resposta iguais a 50%, ou seja,

$$\frac{P_1(W, X|\beta, \gamma)}{P_2(W, X|\beta, \gamma)} = 1.$$

Agora suponha que uma nova alternativa seja adicionado, ônibus azul ($j = 3$) com as mesmas características do ônibus vermelho, então

$$\frac{P_2(W, X|\beta, \gamma)}{P_3(W, X|\beta, \gamma)} = 1,$$

e esperamos as probabilidades resposta 50% para carro, 25% para ônibus vermelho e 25% para ônibus azul. Porém, como a inclusão da alternativa não afeta a razão entre as probabilidades de resposta de carro e ônibus vermelho, as novas probabilidades são iguais a 33%.

- Para resolver este problema, o modelo Neste Logit divide as alternativas em grupos, onde os alternativas dentro de cada grupo são correlacionadas mas não correlacionadas entre diferentes grupos.
- O modelo denota J o número de grupos, N_j alternativas no grupo j e “ jk ” representa a alternativa “ k ” do grupo “ j ”.
- A utilidade de jk -ésima alternativa é dada por

$$U_{jk}^* = W' \beta_{jk} + X'_{jk} \gamma + \epsilon_{jk},$$

onde os erros possuem distribuição GEV generalizada, dada por

$$F(\epsilon_{11}, \dots, \epsilon_{JK_j}) = \exp \left(- \sum_{j=1}^J \left[\sum_{k=1}^{K_j} \exp \left(- \frac{\epsilon_{jk}}{\tau_j} \right) \right]^{\tau_j} \right).$$

- Teorema 26.2: Assuma que a utilidade da alternativa “ jk ” seja $U_{jk}^* = W' \beta_{jk} + X'_{jk} \gamma + \epsilon_{jk} = \mu_{jk} + \epsilon_{jk}$ e os erros com a distribuição GEV generalizada. Então a probabilidade de resposta será $P_{jk} = P_{k|j} P_j$, onde

$$P_{k|j} = \frac{\exp(\mu_{jk}/\tau_j)}{\sum_{m=1}^{K_j} \exp(\mu_{jm}/\tau_j)}$$

e

$$P_j = \frac{\left(\sum_{m=1}^{K_j} \exp(\mu_{jm}/\tau_j) \right)^{\tau_j}}{\sum_{l=1}^J \left(\sum_{m=1}^{K_l} \exp(\mu_{lm}/\tau_l) \right)^{\tau_l}}$$

- A função de log-verossimilhança é dada por

$$l_n(\beta, \gamma) = \sum_{i=1}^n \sum_{j=1}^J \sum_{k=1}^{K_j} \mathbb{I}(Y_i = jk) \left(\log P_{k|j}(W_i, X_i | \beta, \gamma) \right. \\ \left. + \log P_j(W_i, X_i | \beta, \gamma) \right)$$

- O estimador de máxima verossimilhança não tem solução algébrica, então deve ser encontrada numericamente.

- O modelo Mixed Logit generaliza o modelo Logit Condicional, $U_j^* = W' \beta_j + X_j' \gamma + \epsilon_j$, substituindo γ por η ,

$$U_j^* = W' \beta_j + X_j' \eta + \epsilon_j,$$

onde η é uma variável aleatória com distribuição $F(\eta|\alpha)$.

- Permite que as variáveis sejam heterogêneos entre diferentes indivíduos.
- A escolha da distribuição mais comum é a Normal com matriz de covariância diagonal, Normal e Log-Normal.
- Também é possível dividir X_j^* em variáveis sem o coeficiente aleatória, para simplificar o modelo.

- Condicionado em η , as probabilidades de resposta são

$$P_j(w, x|\eta) = \frac{\exp(w' \beta_j + x'_j \eta)}{\sum_{l=1}^J \exp(w' \beta_l + x'_l \eta)}.$$

- E as probabilidades não condicionadas são encontradas integrando

$$P_j(w, x) = \int P_j(w, x|\eta) F(\eta|\alpha),$$

que não tem solução fechada.

- Usualmente são calculadas através de integração de Monte Carlo. A partir de uma amostra pseudo-aleatória $\{\eta_1, \dots, \eta_G\}$ de $F(\eta|\alpha)$, o estimador será

$$\tilde{P}_j(w, x) = \frac{1}{G} \sum_{g=1}^G P_j(w, x|\eta_g).$$

- A integração de Monte Carlo é computacionalmente mais eficiente para η de dimensão maior ou igual a 3, e é computacionalmente intenso para o modelo Logit Condicional sem a aleatoriedade.
- A função de log-verossimilhança é dada por

$$l_n(\beta, \eta) = \sum_{i=1}^n \sum_{j=1}^J \mathbf{I}\{Y_i = j\} \log P_j(W_i, X_i|\beta, \eta).$$

Modelos Probit

Probit Multinomial

- Definição
- Erros
- GHK

Probit Ordenado

- Definição
- Erros
- Exemplos

Modelos de Contagem

Regressões Poisson e Binomial Negativa

- Definição
- Particularidades

Modelo BLP (Nerry, Levinsohn e Parkes)

- Definição (GMM)
- Erros
- Exemplos

Aplicação

